Universidade Federal do Rio Grande do Sul (UFRGS)
Métodos Estatísticos

Relação entre Gols e Expected Goals (xG) em Atacantes das Principais Ligas Europeias

Luciano Blank Fonseca

Porto Alegre
2026

1 Base de Dados

Este trabalho utiliza dados de desempenho ofensivo de jogadores de futebol, obtidos da plataforma (Understat, 2026),uma das principais fontes gratuitas de *Expected Goals* (xG) para as cinco maiores ligas europeias de futebol (Premier League, La Liga, Bundesliga, Serie A e Ligue 1), além do campeonato russo (RFPL). O xG é uma métrica que estima, para cada finalização, a probabilidade de gol com base em características do chute (distância, ângulo, parte do corpo, tipo de jogada,entre outras), permitindo comparar a qualidade das chances criadas por um jogador com o número de gols que ele efetivamente converteu.

Os dados foram acessados por meio de um repositório público que agrega os registros do Understat por jogador e temporada (Understat, 2026), cobrindo as temporadas de 2014/15 a 2025/26.

1.1 Critérios de filtragem e premissas

Para compor a amostra de análise, foram aplicados os seguintes filtros e critérios:

- **Temporadas completas:** foram mantidas apenas as temporadas de 2014/15 a 2024/25. A temporada 2025/26 foi excluída por ela não estar com seus dados completaos, o que tornaria as estatísticas de gols e xG não comparáveis às demais (amostra parcial).
- **Posição:** foram selecionados apenas jogadores cuja posição primária registrada na base é atacante (*Forward*, código "F"), de modo a manter a amostra restrita ao grupo de interesse (finalizadores).
- **Volume mínimo de gols:** foram mantidos apenas jogadores com no mínimo 10 gols na temporada. Esse corte busca reduzir o ruído estatístico presente na razão gols/xG quando o número de eventos (gols) é muito baixo, e concentrar a análise em atacantes com participação relevante no ataque de suas equipes.
- **Registros por temporada:** cada linha da base representa o desempenho de um jogador em uma temporada, permitindo que o mesmo atleta apareça em múltiplas temporadas.

Após a aplicação desses critérios, a amostra final contém $n = 1.139$ observações (jogador por temporada), distribuídas entre as seis ligas cobertas pela base.

Limitação a registrar: o critério de gols mínimos seleciona a amostra por um resultado que está relacionado à própria variável de interesse (gols em relação ao xG). Jogadores com poucos gols e xG muito baixo têm maior chance de atingir o corte justamente por terem tido uma finalização acima do esperado na temporada. Essa limitação metodológica é discutida com mais detalhe na Seção 2.2.1 e será aprofundada na próxima etapa do trabalho.

1.2 Variável primária

A variável a ser estudada é a relação entre gols marcados pelos atacantes e a razão pelo seu xG, ou seja, quantos dos gols esperados que um atacante tenha marcado, ele de fato marcou. A ideia por trás dessa variável é avaliar se os atacantes das principais ligas europeias, que se espera que sejam os melhores do mundo, convertem mais gols do que se espera deles. Dessa forma, esse indicador gols/xG serve como um medidor de eficiência, verificando se um atacante faz mais ou menos gols do que se espera dele e, por consequência, podendo verificar se os melhores jogadores (Messi, Cristiano Ronaldo, Neymar) convertem a cima do esperado.

2 Resultados

2.1 Estatísticas descritivas

A Tabela 1 apresenta as principais estatísticas descritivas para o número de gols, o xG acumulado na temporada e a razão gols/xG, que é a variável central desta análise: valores acima de 1 indicam que o jogador converteu mais gols do que o esperado pela qualidade média de suas chances; valores abaixo de 1 indicam o oposto.

Tabela 1: Estatísticas descritivas — atacantes com 10 ou mais gols na temporada

Variável	Média	Mediana	Desvio-padrão	Mínimo	Máximo	Assimetria
Gols	14,65	13,00	5,33	10,00	48,00	1,98
xG	13,27	11,93	5,37	3,39	39,31	1,41
Gols / xG	1,16	1,12	0,27	0,56	2,95	1,17

Em média, os atacantes da amostra converteram 14,65 gols contra um xG médio de 13,27, o que já sugere uma leve superação do esperado. A razão gols/xG apresenta média de 1,16 e mediana de 1,12, com desvio-padrão de 0,27. O coeficiente de assimetria (1,17) indica uma distribuição com cauda mais longa à direita, isto é, há mais casos de jogadores que superam bastante o xG do que casos de subperformance extrema.

2.2 Distribuição da razão gols/xG

A Figura 1 mostra o histograma da razão gols/xG, com a curva de densidade estimada (linha contínua) sobreposta a uma curva normal ajustada com a mesma média e desvio-padrão (linha tracejada), além de referências para a razão neutra (gols/xG $= 1$, linha vermelha), a média e a mediana amostrais.

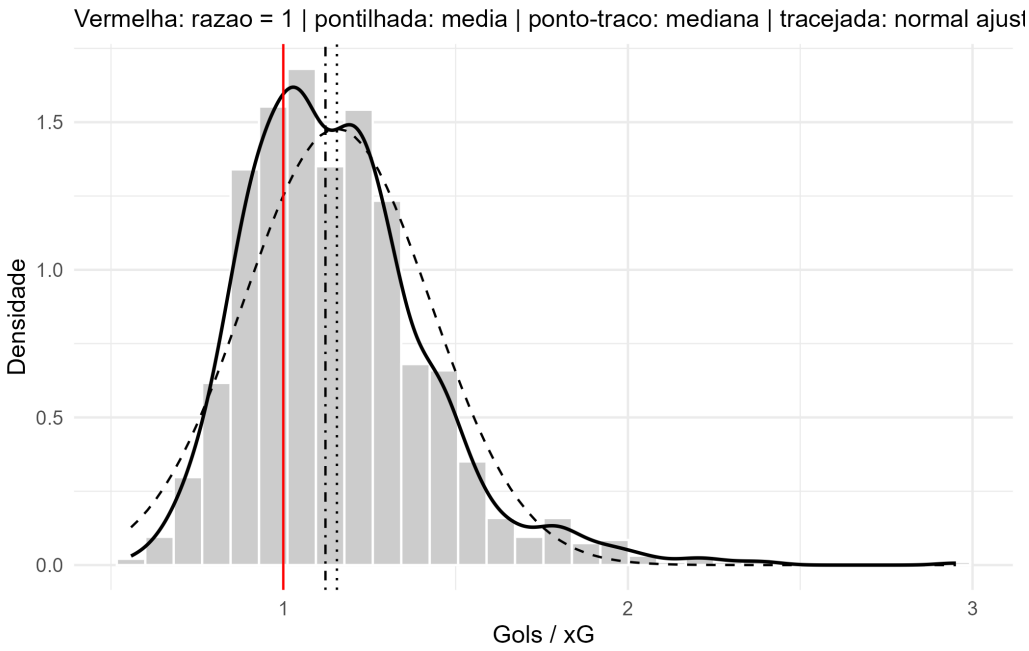


Figura 1: Distribuição da razão gols/xG

Observa-se que a distribuição não é simétrica: a maior parte dos jogadores se concentra logo acima de 1, com uma cauda direita mais longa formada por temporadas de forte superação do xG. Essa assimetria é reforçada com o gráfico quantil-quantil, no qual os pontos se afastam da reta de referência principalmente na extremidade superior, indicando que a distribuição normal não descreve bem os valores mais altos da razão gols/xG.

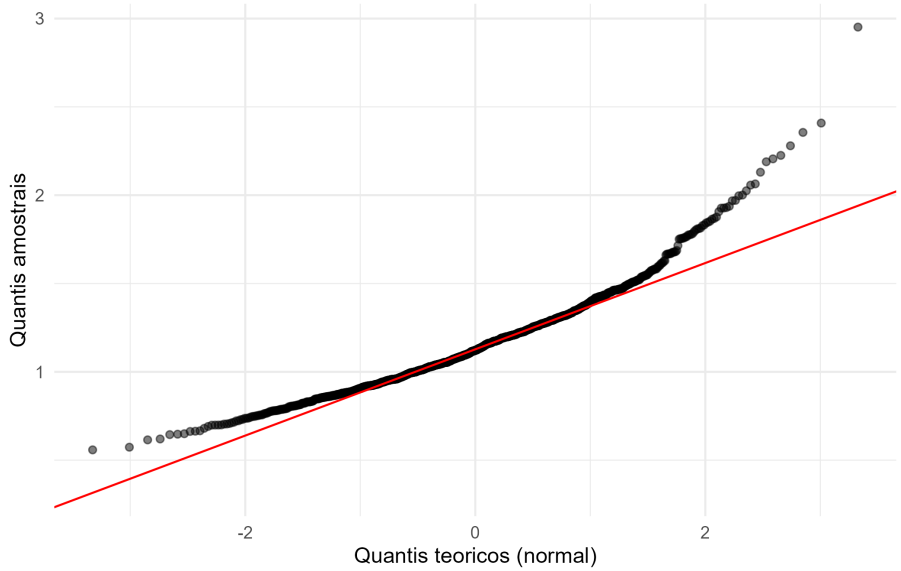


Figura 2: Gráfico quantil-quantil (QQ-plot) da razão gols/xG frente à distribuição normal

2.2.1 O efeito do limiar de 10 gols

Ao observar individualmente as temporadas com as maiores razões gols/xG da amostra, nota-se um padrão relevante: a grande maioria delas pertence a jogadores com número de gols muito próximo ao limiar mínimo de corte (10 a 13 gols), e não aos maiores artilheiros da amostra. A Tabela 2 ilustra esse padrão com alguns exemplos.

Tabela 2: Exemplos de temporadas com maior e menor razão gols/xG

Jogador	Temporada	Gols	xG	Gols/xG
Maiores razões				
Mason Greenwood	2019/20	10	3,39	2,95
Jeremie Boga	2019/20	11	4,57	2,41
James Rodríguez	2014/15	13	5,52	2,36
Menores razões				
Darwin Núñez	2023/24	11	19,19	0,57
Robert Lewandowski	2018/19	22	33,14	0,66
Gabriel Jesus	2019/20	14	21,02	0,67

Esse padrão é esperado dado o desenho da amostra, pois como o critério de inclusão exige apenas 10 gols, um jogador com xG muito baixo (por exemplo, 3,4) só entra na base se tiver convertido muito acima do esperado naquela temporada, caso contrário, ele nem apareceria na amostra. Assim, as razões mais extremas tendem a se concentrar exatamente nos jogadores com menor volume de gols, e não necessariamente nos atacantes mais eficientes em termos absolutos.

Por outro lado, mesmo atacantes reconhecidamente eficientes podem apresentar temporadas de subperformance frente ao xG: Robert Lewandowski, por exemplo, converteu 22 gols contra um xG acumulado de 33,14 na temporada 2018/19 (razão de 0,66), evidenciando que a razão gols/xG de uma única temporada reflete tanto a capacidade de finalização do jogador quanto a variabilidade natural do desempenho ao longo de uma temporada, um único ano de amostra não é suficiente para isolar completamente o efeito da habilidade.

2.3 Comparação entre ligas

A Figura 3 apresenta a distribuição da razão gols/xG por liga, por meio de boxplots. As medianas das cinco maiores ligas europeias são bastante próximas entre si e levemente acima de 1, com a liga russa (RFPL) apresentando uma mediana visivelmente mais alta que as demais.

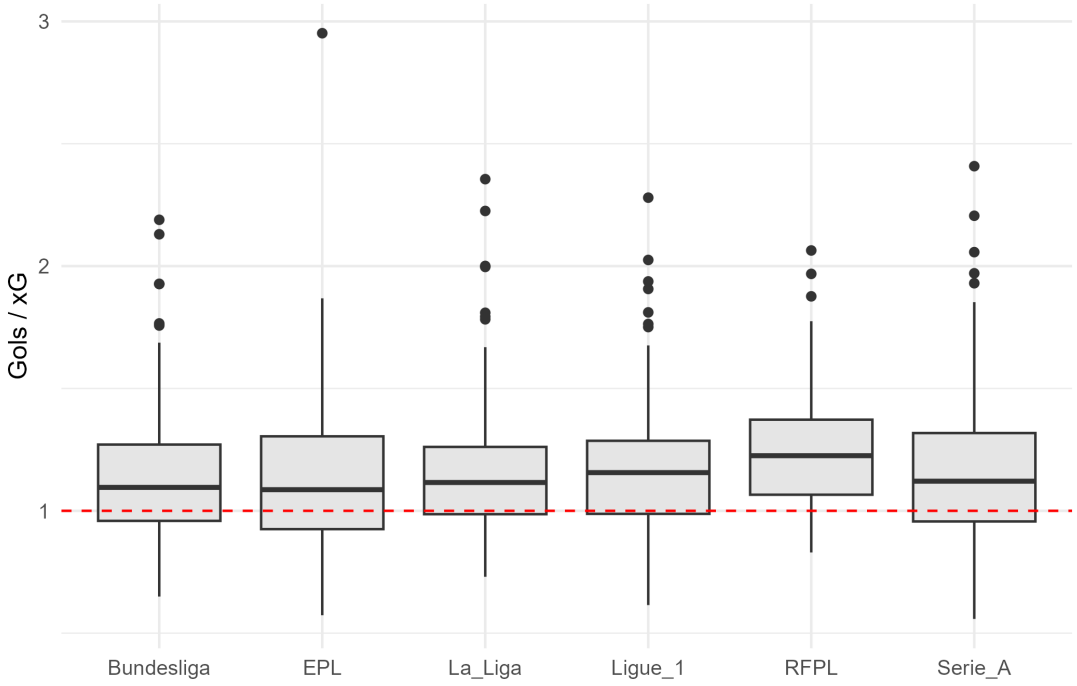


Figura 3: Razão gols/xG por liga

2.4 Relação entre xG e gols

Por fim, a Figura 4 apresenta a relação entre o xG acumulado na temporada e o número de gols efetivamente marcados, evidenciando uma associação positiva forte entre as duas variáveis: quanto maior o xG acumulado por um atacante, maior tende a ser o seu número de gols na temporada.

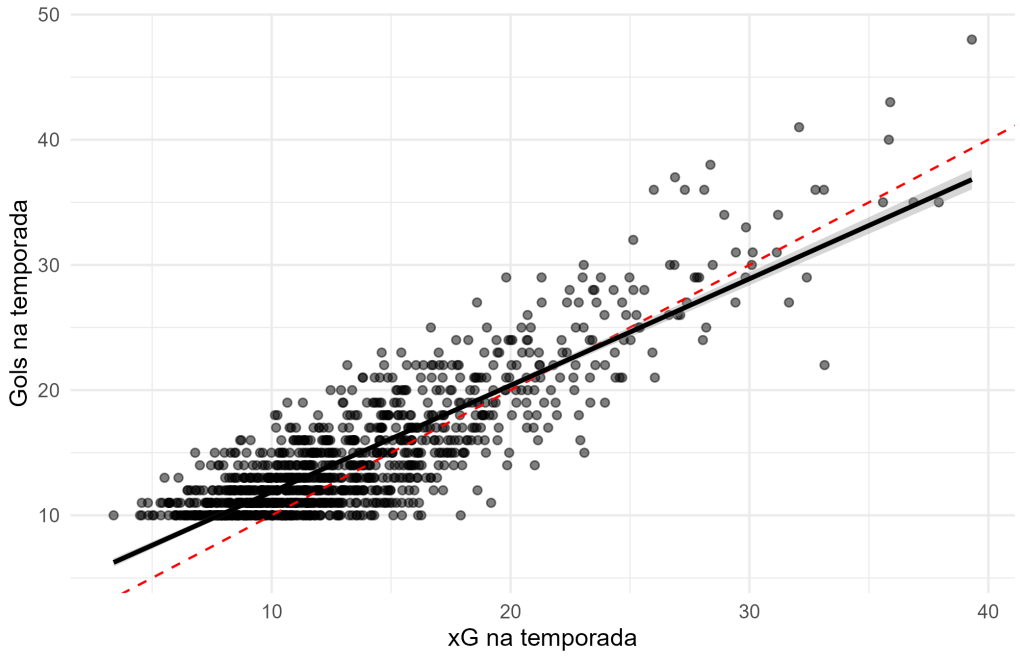


Figura 4: Relação entre xG e gols na temporada

2.5 Testes de normalidade e de hipótese

Para conseguir verificar a normalidade sugerida pelos gráficos da Seção 2.2.1, foi aplicado o teste de Shapiro-Wilk sobre a razão gols/xG, que rejeitou a hipótese de normalidade ($p < 0,001$), confirmando o afastamento observado no QQ-plot (Figura 2). Em seguida, testou-se formalmente se a média da razão gols/xG é igual a 1, ou seja, se os atacantes da amostra, em média, convertem exatamente o número de gols esperado pelo xG. O teste t para uma amostra rejeitou essa hipótese ($t = 19{,}45$; $p < 0{,}001$), confirmando que a média de 1,16 observada na Tabela 1 é estatisticamente maior que 1, e não apena fruto de variação amostral. Também foi testada a correlação entre xG e gols, sugerida visualmente pela Figura 4. O teste de correlação de Pearson indicou uma associação forte e significativa entre as duas variáveis ($r \approx 0{,}86$; $p < 0{,}001$), confirmando que o xG acumulado é um bom preditor do número de gols marcados na temporada.

2.6 Comparação estatística entre ligas

Para verificar se a diferença visual entre ligas observada na Figura 3 é estatisticamente significativa, foi aplicado o teste de Kruskal-Wallis sobre a razão gols/xG entre as seis ligas, que indicou diferença significativa entre pelo menos um par de ligas ($p = 0{,}014$). A comparação par a par (teste de Wilcoxon, com correção de Holm) mostrou que essa diferença é explicada pela liga russa (RFPL), que difere das demais ligas ($p < 0{,}05$ frente à Premier League, La Liga e Bundesliga), enquanto as cinco maiores ligas europeias não diferem significativamente entre si ($p \approx 1$ em todas as comparações). Isso sugere que o padrão de finalização dos atacantes é relativamente homogêneo entre as principais ligas europeias, com a liga russa se destacando como um caso à parte.

3 Considerações Finais

Os resultados descritivos indicam que, na amostra analisada, os atacantes tendem a converter, em média, um número de gols levemente superior ao esperado pelo xG, com distribuição assimétrica à direita. As cinco maiores ligas europeias apresentam comportamento semelhante entre si quanto à razão gols/xG, o que não se observa de forma tão clara na liga russa. Uma observação importante é que as razões mais extremas de gols/xG concentram-se em jogadores próximos ao limiar mínimo de gols usado no filtro da amostra, o que reforça que grande parte da variação observada advém de flutuação amostral de curto prazo e não necessariamente de diferenças estáveis de habilidade entre os atacantes. Dessa forma, mesmo finalizadores consagrados, como Robert Lewandowski, podem registrar temporadas isoladas de desempenho abaixo do esperado.

Referências

Understat. *Understat player season statistics: dados agregados por jogador e temporada*. 2026. <https://github.com/vibedatascience/understat_players_aggregated>. Repositório público que agrega dados coletados do site Understat (<https://understat.com>).